



El Perceptrón y el Perceptrón Multicapa

Fundamentos Teóricos y Funcionamiento Interno

Autor: Jesús Emmanuel Martínez García

Introducción

- El perceptrón es la **unidad básica de una red neuronal artificial**.
- Fue propuesto por **Frank Rosenblatt (1958)**.
- Su objetivo: **imitar el comportamiento de una neurona biológica** para realizar tareas de clasificación.

 Aplicaciones: reconocimiento de patrones, clasificación lineal, procesamiento de señales, etc.

Estructura de una Neurona Artificial

- Entrada: vector de características ($x = [x_1, x_2, \dots, x_n]$)
- Pesos: ($w = [w_1, w_2, \dots, w_n]$)
- Umbral o sesgo: (b)
- Salida: ($y = f(z)$), donde ($z = w \cdot x + b$)



Funcionamiento Matemático

1. Suma ponderada:

$$z = \sum_{i=1}^n w_i x_i + b$$

2. Función de activación:

Decide si la neurona se activa o no.


Ejemplo (función escalón):

$$f(z) = \begin{cases} 1 & \text{si } z > 0 \\ 0 & \text{si } z \leq 0 \end{cases}$$

3. Salida final:

$$y = f(z)$$

🧩 Ejemplo Visual del Perceptrón Simple



- Clasifica puntos en dos clases (líneas separables linealmente).
- Si los datos **no son linealmente separables**, el perceptrón **falla**.

Limitaciones del Perceptrón Simple


- Solo puede resolver **problemas linealmente separables**.
- No puede aprender funciones como **XOR**.
- No maneja relaciones complejas entre variables.

 Para solucionar esto surge el **Perceptrón Multicapa (MLP)**.



Perceptrón Multicapa (MLP)

- Extiende la idea del perceptrón simple añadiendo **capas ocultas**.
- Cada capa aprende **representaciones intermedias**.
- Se compone de:
 - Capa de entrada
 - Una o más capas ocultas
 - Capa de salida





Propagación hacia Adelante (Forward Propagation)

1. Cada neurona calcula su salida:

$$a_j^{(l)} = f \left(\sum_i w_{ji}^{(l)} a_i^{(l-1)} + b_j^{(l)} \right)$$

2. Las salidas se propagan capa por capa hasta la salida final.



Funciones de activación comunes:

- Sigmoid: ($f(x) = \frac{1}{1 + e^{-x}}$)
- ReLU: ($f(x) = \max(0, x)$)
- Tanh: ($f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$)

Retropropagación del Error (Backpropagation)

- Mecanismo de **aprendizaje supervisado**.
- Calcula el error entre la salida predicha y la deseada.
- Propaga ese error hacia atrás para ajustar los pesos:

$$w_{ij}^{(l)} \leftarrow w_{ij}^{(l)} - \eta \frac{\partial E}{\partial w_{ij}^{(l)}}$$

Donde:


- (E): error global
- (η): tasa de aprendizaje

Aprendizaje del MLP

1. Inicializa pesos aleatoriamente
2. Calcula salida (forward)
3. Mide el error (función de pérdida)
4. Propaga el error (backpropagation)
5. Actualiza pesos
6. Repite hasta convergencia



Ejemplo de Clasificación con MLP



- El MLP puede **aprender fronteras no lineales**.
- Permite resolver problemas como **XOR** o reconocimiento de imágenes simples.


Comparación: Perceptrón Simple vs. Multicapa

Característica	Perceptrón Simple	MLP
Nº de capas ocultas	0	≥ 1
Función de activación	Escalón	No lineal (ReLU, Sigmoid, etc.)
Tipo de problemas	Lineales	No lineales
Algoritmo de entrenamiento	Regla del perceptrón	Backpropagation
Capacidad de aprendizaje	Limitada	Alta

🧩 Ejemplo: Solución del Problema XOR

- Perceptrón simple: ❌ no puede separar clases
- MLP con una capa oculta: ✅ logra separación no lineal

Esquema Perceptrón para puerta lógica XOR



X = Entradas

W = Pesos

θ = Umbral

$$y1 = f((X1 * w11) + (X2 * w12) + (1 * \theta1))$$

$$y2 = f((X1 * w21) + (X2 * w22) + (1 * \theta2))$$

$$Y3 = f((y1 * w31) + (y2 * w32) + (1 * \theta3))$$

<http://censormico.blogspot.com.es/>

Interpretación Conceptual

- Cada capa aprende una **representación más abstracta** de los datos.
- En capas profundas, las neuronas aprenden **características complejas**.
- Este principio es la base del **Deep Learning**.



Conclusiones

- ✓ El perceptrón fue el primer modelo de red neuronal.
- ✓ El perceptrón multicapa superó sus limitaciones mediante el uso de capas ocultas.
- ✓ El entrenamiento mediante **backpropagation** es la base del aprendizaje profundo.
- ✓ Comprender su funcionamiento es esencial para entender las **redes neuronales modernas**.

Referencias

- Rosenblatt, F. (1958). *The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain*.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Nielsen, M. (2015). *Neural Networks and Deep Learning*.