

Ciencia de Datos

Datos masivos, plataformas y selección de herramientas

¿Qué es Big Data?

Un conjunto de datos tan **grande, veloz o complejo** que las herramientas tradicionales no pueden capturarlo, gestionarlo ni procesarlo eficientemente.

- No se trata solo del volumen — también de la **velocidad** y la **variedad**
- Requiere infraestructura y enfoques distintos al análisis convencional
- Su correcta gestión es la base de cualquier proyecto de Ciencia de Datos

Las 5 V's del Big Data

Las 5 V's

V	Concepto	Ejemplo
Volumen	Cantidad masiva de datos	Millones de transacciones por día
Velocidad	Rapidez de generación y procesamiento	Tweets en tiempo real
Variedad	Múltiples formatos y fuentes	Texto, imágenes, audio, JSON
Veracidad	Calidad y confiabilidad del dato	Datos ruidosos o incompletos
Valor	Utilidad extraída de los datos	Predicción, optimización, ahorro

Ejemplos de Big Data en el mundo real

- **Redes sociales** — Facebook procesa ~500 TB de datos nuevos cada día
- **IoT / Manufactura** — sensores generan millones de lecturas por hora
- **Salud** — registros clínicos, imágenes médicas, secuencias genómicas
- **Finanzas** — detección de fraude en tiempo real sobre millones de transacciones
- **Transporte** — Uber y Waze procesan rutas y tráfico de millones de usuarios simultáneamente

El Big Data **no es una moda** — es la materia prima del siglo XXI.

Plataformas para análisis de datos

Ecosistema de herramientas

Almacenamiento y procesamiento distribuido

- `Apache Hadoop` — procesamiento paralelo de grandes volúmenes (MapReduce)
- `Apache Spark` — más rápido que Hadoop; procesamiento en memoria

Bases de datos

- `SQL` (MySQL, PostgreSQL) — datos estructurados, relacionales
- `NoSQL` (MongoDB, Cassandra) — datos no estructurados o semiestructurados

Nube

- `Google BigQuery` · `AWS S3 + Athena` · `Azure Synapse`

Plataformas para Ciencia de Datos

Entornos de desarrollo

- `Jupyter Notebook` — interactivo, ideal para exploración
- `Google Colab` — gratuito, con GPU/TPU en la nube
- `VS Code` — para proyectos más estructurados

Gestión de datos y flujos

- `Apache Airflow` — orquestación de pipelines
- `dbt` — transformación de datos en SQL

Visualización empresarial

- `Power BI` · `Tableau` · `Looker`

Selección de herramientas

¿Cómo elegir la herramienta correcta?

No existe una sola herramienta que sirva para todo. La selección depende de:

 **Volumen y tipo de datos** — ¿estructurados, semiestructurados, en tiempo real?

 **Objetivo del análisis** — ¿exploración, predicción, reporte, despliegue?

 **Infraestructura disponible** — ¿local, nube, híbrido?

 **Perfil del equipo** — ¿analistas, ingenieros, científicos de datos?

Comparativa de herramientas

Criterio	Python + pandas	Apache Spark	Power BI
Facilidad de uso	Alta	Media	Alta
Escalabilidad	Media	Muy alta	Media
Ideal para	Análisis y ML	Big Data real	Reportes
Costo	Gratuito	Gratuito	Freemium
Curva de aprendizaje	Baja-Media	Alta	Baja

Fuentes de datos públicas

Existen repositorios abiertos con datasets listos para practicar:

- **Kaggle** ([kaggle.com](https://www.kaggle.com)) — competencias y datasets de todo tipo
- **UCI ML Repository** — datasets clásicos para machine learning
- **datos.gob.mx** — datos abiertos del gobierno mexicano
- **Google Dataset Search** — motor de búsqueda de datasets
- **INEGI** — datos demográficos, económicos y sociales de México
- **World Bank Open Data** — indicadores globales de desarrollo

Una buena fuente de datos puede definir el éxito de un proyecto.

Actividad práctica — Semana 2

Exploración guiada de plataformas

1. Crear cuenta en **Kaggle** y descargar un dataset de interés
2. Abrir el dataset en **Google Colab** con `pandas`
3. Ejecutar las primeras inspecciones: `df.head()`, `df.info()`, `df.describe()`
4. Identificar: ¿qué tipo de datos contiene? ¿Hay valores nulos?
5. Reflexión escrita: ¿**qué herramienta usarías para analizar este dataset a escala?**

Para esta semana

- [] Comprender las 5 V's del Big Data y reconocerlas en ejemplos reales
- [] Identificar las principales plataformas para análisis de datos
- [] Aplicar criterios para seleccionar la herramienta adecuada según el contexto
- [] Explorar al menos una fuente de datos pública y cargarla en Colab

Próxima sesión

Adquisición · limpieza · transformación · fuentes de datos públicas