

Ciencia de Datos

Minería de datos y proceso ETL: del dato crudo al dato útil

¿Qué es la Minería de Datos?

El proceso de **descubrir patrones, correlaciones y anomalías** dentro de grandes conjuntos de datos para predecir resultados.

- Va más allá de consultar datos — **extrae conocimiento oculto**
- Combina estadística, aprendizaje automático y bases de datos
- Es la base del análisis predictivo y descriptivo

Sin minería de datos, los datos masivos son solo ruido.

Tareas principales en Minería de Datos

Tarea	¿Qué hace?	Ejemplo
Clasificación	Asigna categorías a registros	¿Es fraude o no?
Clustering	Agrupar elementos similares	Segmentar clientes
Regresión	Predice valores numéricos	Precio de una vivienda
Asociación	Encuentra relaciones entre variables	"Quienes compran X también compran Y"
Detección de anomalías	Identifica datos atípicos	Transacción inusual

El proceso ETL

¿Qué significa ETL?

ETL = Extract · Transform · Load

Es el proceso estándar para mover datos desde sus fuentes originales hasta un sistema donde puedan analizarse.



Extract (Extraer) — obtener datos desde las fuentes originales



Transform (Transformar) — limpiar, estandarizar y estructurar los datos



Load (Cargar) — depositar los datos listos en el destino final

E — Extracción de datos

¿De dónde vienen los datos?

- **Bases de datos relacionales** — MySQL, PostgreSQL, SQL Server
- **Archivos planos** — CSV, Excel, JSON, XML
- **APIs** — Twitter/X, clima, finanzas, gobierno
- **Web scraping** — extracción automatizada de sitios web
- **Sensores / IoT** — lecturas en tiempo real
- **Sistemas empresariales** — ERP, CRM, SAP

El primer reto es saber **dónde están los datos** y cómo acceder a ellos.

T — Transformación y limpieza de datos

Esta es la etapa más costosa en tiempo: **60–80 % del trabajo real de un proyecto de datos.**

Problemas comunes que se resuelven aquí:

- Valores nulos o faltantes (NaN)
- Duplicados en registros
- Tipos de datos incorrectos (fechas como texto, números como string)
- Inconsistencias de formato (CDMX vs Ciudad de México vs DF)
- Outliers o valores extremos que distorsionan el análisis
- Datos en diferentes escalas o unidades

Técnicas de limpieza con Python

```
import pandas as pd

df = pd.read_csv("datos.csv")

# Revisar valores nulos
df.isnull().sum()

# Eliminar filas con nulos
df.dropna(inplace=True)

# Rellenar nulos con la media
df['edad'].fillna(df['edad'].mean(), inplace=True)

# Eliminar duplicados
df.drop_duplicates(inplace=True)

# Convertir tipo de dato
df['fecha'] = pd.to_datetime(df['fecha'])
```


T — Transformación: más allá de limpiar

Limpiar no es suficiente — también hay que **estructurar y enriquecer** los datos:

- **Normalización** — escalar variables a un rango común (0–1)
- **Codificación** — convertir categorías en valores numéricos (`LabelEncoder`, `get_dummies`)
- **Agregación** — resumir datos por grupo, fecha, región
- **Feature engineering** — crear nuevas variables útiles a partir de las existentes
- **Integración** — combinar múltiples fuentes en una sola tabla (`merge`, `join`)

L — Carga de datos

Una vez limpios y transformados, los datos se depositan en su destino:

Destino	Uso típico
Data Warehouse	Análisis histórico y reportes empresariales
Data Lake	Almacenamiento masivo de datos crudos y procesados
Base de datos relacional	Aplicaciones operativas
Archivo CSV / Parquet	Análisis exploratorio, modelos locales
Dashboard (Power BI, Tableau)	Visualización para stakeholders

Fuentes de datos públicas

Datos abiertos en México y el mundo


México

- [datos.gob.mx](#) — portal oficial de datos abiertos del gobierno federal
- [INEGI](#) — estadísticas de población, economía, vivienda
- [Banxico](#) — indicadores financieros y económicos
- [SSA / IMSS](#) — datos de salud pública

Internacional

- [Kaggle](#) — datasets de todo tipo para práctica y competencias
- [UCI ML Repository](#) — clásicos del machine learning
- [World Bank Open Data](#) — indicadores de desarrollo global

Ciclo completo: de la fuente al insight



Actividad práctica — Semana 3

Mini pipeline ETL en Google Colab

1. Elegir un dataset de `datos.gob.mx` o `Kaggle`
2. **Extraer**: cargar el dataset con `pandas` (`pd.read_csv`)
3. **Explorar**: `df.shape`, `df.info()`, `df.isnull().sum()`
4. **Transformar**: limpiar nulos, corregir tipos de datos, eliminar duplicados
5. **Cargar**: guardar el resultado limpio como `datos_limpios.csv`
6. Documentar brevemente qué problemas encontraron y cómo los resolvieron

Para esta semana

- [] Comprender qué es la minería de datos y sus tareas principales
- [] Entender cada etapa del proceso ETL (Extracción, Transformación, Carga)
- [] Aplicar técnicas básicas de limpieza de datos con `pandas`
- [] Explorar al menos una fuente de datos pública nacional o internacional
- [] Completar el mini pipeline ETL de la actividad práctica

Próxima sesión

Diseño de tableros interactivos · KPIs · herramientas de visualización · **Evaluación**
Unidad I