

# Ciencia de Datos

---

Medidas de tendencia central y dispersión · Análisis estadístico descriptivo

# ¿Por qué estadística en Ciencia de Datos?

Antes de entrenar cualquier modelo, necesitas **entender tus datos**. La estadística descriptiva es el primer paso.

- Resume grandes volúmenes de datos en valores **comprensibles**
- Permite detectar **anomalías, sesgos y patrones** antes del modelado
- Es la base para evaluar si un modelo está funcionando correctamente

# Medidas de Tendencia Central

*¿Dónde se concentran los datos?*

# Media, Mediana y Moda

| Medida  | Definición                         | Cuándo usarla              |
|---------|------------------------------------|----------------------------|
| Media   | Suma de valores ÷ total de datos   | Datos sin valores extremos |
| Mediana | Valor central al ordenar los datos | Datos con valores atípicos |
| Moda    | Valor que más se repite            | Variables categóricas      |

## Ejemplo práctico:

Salarios en una empresa: [18 000, 19 000, 20 000, 21 000, 95 000]

- Media: **34 600** ← el directivo distorsiona
- Mediana: **20 000** ← más representativa
- Moda: *no aplica* (todos distintos)

# Media: detalles importantes

 **Fórmula:**  $\bar{x} = (\sum x_i) / n$

## Tipos de media que encontrarás:

- **Media aritmética** — la más común, suma simple
- **Media ponderada** — cuando los datos tienen diferente peso
- **Media móvil** — para series de tiempo, suaviza tendencias

```
import numpy as np
datos = [18000, 19000, 20000, 21000, 95000]
print(np.mean(datos))      # 34600.0
print(np.median(datos))    # 20000.0
```

# Medidas de Dispersión

*¿Qué tan separados están los datos entre sí?*

# Varianza y Desviación Estándar

La tendencia central nos dice *dónde* están los datos. La dispersión nos dice *qué tan agrupados* están.

▢ **Varianza ( $\sigma^2$ ):** promedio de las diferencias al cuadrado respecto a la media

▢ **Desviación estándar ( $\sigma$ ):** raíz cuadrada de la varianza — misma unidad que los datos

**Regla práctica:**  $\sigma$  pequeña = datos muy concentrados ·  $\sigma$  grande = datos muy dispersos

# Varianza y $\sigma$ en Python

```
import numpy as np
import pandas as pd

datos = [10, 12, 14, 16, 18]

varianza = np.var(datos) # 8.0
desv_std = np.std(datos) # 2.83
desv_muestral = np.std(datos, ddof=1) # 3.16 ← usa n-1

# Con pandas
serie = pd.Series(datos)
print(serie.describe())
```

⚠ Usa `ddof=1` cuando trabajas con una **muestra** (lo más común en práctica).



# Otras medidas de dispersión

| Medida                   | Descripción                   | Uso típico                                    |
|--------------------------|-------------------------------|-----------------------------------------------|
| Rango                    | Máx – Mín                     | Vista rápida del rango de valores             |
| IQR                      | Q3 – Q1                       | Robusto ante valores atípicos                 |
| Coeficiente de variación | $\sigma / \bar{x} \times 100$ | Comparar dispersión entre variables distintas |

**El IQR (Rango Intercuartílico)** es clave para detectar *outliers*:

- Outlier leve: valor  $< Q1 - 1.5 \times IQR$  o  $> Q3 + 1.5 \times IQR$
- Outlier extremo: factor  $3 \times IQR$

# Coeficiente de Correlación

*¿Cómo se relacionan dos variables?*

# Correlación de Pearson

Mide la **fuerza y dirección** de la relación lineal entre dos variables numéricas.

| Valor de r         | Interpretación                |
|--------------------|-------------------------------|
| $r = 1.0$          | Correlación positiva perfecta |
| $0.7 \leq r < 1.0$ | Correlación positiva fuerte   |
| $0.3 \leq r < 0.7$ | Correlación positiva moderada |
| $r \approx 0$      | Sin correlación lineal        |
| $r < 0$            | Correlación negativa          |

 **Correlación  $\neq$  Causalidad** — siempre contextualiza el resultado.

# Correlación en Python

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

df = pd.read_csv('datos.csv')

# Correlación entre dos columnas
r = df['horas_estudio'].corr(df['calificacion'])
print(f"r = {r:.2f}")

# Mapa de correlaciones (heatmap)
sns.heatmap(df.corr(), annot=True, cmap='Greens',
            vmin=-1, vmax=1)
plt.title('Matriz de correlación')
plt.show()
```

# **Tendencia de datos y análisis exploratorio**

# El proceso EDA (Exploratory Data Analysis)

1. **Cargar y revisar** — `df.head()`, `df.info()`, `df.describe()`
2. **Distribuciones** — histogramas, boxplots para cada variable
3. **Tendencia central** — media, mediana por grupos
4. **Dispersión** — desviación estándar, IQR, outliers
5. **Correlaciones** — heatmap, scatter plots
6. **Conclusiones** — ¿qué nos dicen los datos antes de modelar?

 **Meta del EDA:** conocer tus datos tan bien que ningún resultado del modelo te sorprenda completamente.

# Visualización de distribuciones

```
import matplotlib.pyplot as plt
import seaborn as sns

fig, axes = plt.subplots(1, 2, figsize=(12, 4))

# Histograma
axes[0].hist(df['variable'], bins=20, color='#3a7a10', edgecolor='white')
axes[0].set_title('Distribución')

# Boxplot – muestra mediana, IQR y outliers
sns.boxplot(y=df['variable'], ax=axes[1], color='#c5dba5')
axes[1].set_title('Boxplot')

plt.tight_layout()
plt.show()
```

Un **boxplot** muestra de un vistazo: mediana, cuartiles y outliers.

## Resumen: ¿qué mide cada estadístico?

| Pregunta                             | Estadístico                        |
|--------------------------------------|------------------------------------|
| ¿Dónde están concentrados los datos? | Media, mediana, moda               |
| ¿Qué tan dispersos están?            | Varianza, desviación estándar, IQR |
| ¿Hay valores extremos?               | Rango, IQR, boxplot                |
| ¿Dos variables se mueven juntas?     | Coeficiente de correlación $r$     |
| ¿Cómo luce la distribución completa? | Histograma, curva de densidad      |



## Para esta semana

- [ ] Calcular media, mediana y moda de un dataset real con `pandas`
- [ ] Obtener varianza y desviación estándar e interpretar el resultado
- [ ] Generar un **boxplot** e identificar posibles outliers
- [ ] Construir una **matriz de correlación** y leer los valores
- [ ] Reflexión: **¿qué nos revelan estas métricas sobre la calidad de los datos?**

# Próxima sesión

---

Fundamentos · obtención de la ecuación · predicciones a partir del modelo