

Ciencia de Datos

Análisis de regresión lineal: fundamentos, ecuación y predicciones

¿Qué es la regresión lineal?

Un método estadístico que modela la **relación entre una variable dependiente** y una o más variables independientes mediante una **línea recta**.

- Permite **cuantificar** cómo cambia Y cuando X varía
- Es la base de muchos modelos predictivos más complejos
- Su salida es una ecuación interpretable: $\hat{y} = \beta_0 + \beta_1 x$

Tipos de regresión lineal

Tipo	Descripción	Ejemplo
Simple	Una variable predictora	Horas de estudio → calificación
Múltiple	Varias variables predictoras	Precio de casa → m ² , ubicación, antigüedad

En esta sesión nos enfocamos en la **regresión lineal simple** como fundamento.

Fundamentos matemáticos

La ecuación de la recta

La forma general del modelo es:

$$\hat{y} = \beta_0 + \beta_1 x$$

Término	Nombre	Significado
$\hat{y}$	Variable dependiente	Valor predicho
x	Variable independiente	Variable predictora
β_0	Intercepto	Valor de Y cuando $X = 0$
β_1	Pendiente	Cambio en Y por cada unidad de X

Estimación de coeficientes (Mínimos Cuadrados)

El objetivo es **minimizar la suma de los errores al cuadrado (SSE)**:

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Las fórmulas de los coeficientes son:

$$\beta_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} \quad \beta_0 = \bar{y} - \beta_1 \bar{x}$$

Supuestos del modelo

 **Linealidad** — la relación entre X e Y es lineal

 **Independencia** — las observaciones son independientes entre sí

 **Homocedasticidad** — varianza constante de los errores

 **Normalidad** — los residuos siguen una distribución normal

Métricas de evaluación del modelo

¿Qué tan bueno es el modelo?

Coeficiente de determinación R^2

$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

Valor de R^2	Interpretación
0.0 – 0.3	Ajuste débil
0.3 – 0.7	Ajuste moderado
0.7 – 1.0	Ajuste fuerte
1.0	Ajuste perfecto (sospechar sobreajuste)

Otras métricas clave

Métrica	Fórmula	Interpretación
MAE	$\text{mean} y - \hat{y} $	Error absoluto promedio
MSE	$\text{mean}(y - \hat{y})^2$	Penaliza errores grandes
RMSE	$\sqrt{\text{MSE}}$	En las mismas unidades que Y
R²	$1 - \text{SSE}/\text{SST}$	Proporción de varianza explicada

RMSE es la métrica más común para reportar el desempeño en regresión.

Implementación en Python

Regresión lineal con scikit-learn

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score
from sklearn.model_selection import train_test_split

# Datos de ejemplo: horas de estudio vs calificación
X = np.array([1, 2, 3, 4, 5, 6, 7, 8]).reshape(-1, 1)
y = np.array([45, 55, 60, 65, 70, 75, 85, 90])

# División entrenamiento / prueba
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.25, random_state=42
)
```

Entrenamiento y predicción

```
# Crear y entrenar el modelo
modelo = LinearRegression()
modelo.fit(X_train, y_train)

# Coeficientes
print(f"Intercepto ( $\beta_0$ ): {modelo.intercept_:.2f}")
print(f"Pendiente ( $\beta_1$ ): {modelo.coef_[0]:.2f}")

# Predicciones
y_pred = modelo.predict(X_test)

# Métricas
rmse = np.sqrt(mean_squared_error(y_test, y_pred))
r2 = r2_score(y_test, y_pred)
print(f"RMSE: {rmse:.2f}")
print(f"R²: {r2:.4f}")
```

Visualización del modelo

```
# Datos completos + línea de regresión
plt.figure(figsize=(8, 5))
plt.scatter(X, y, color='#27500A', label='Datos reales', zorder=5)
plt.plot(X, modelo.predict(X),
         color='#5aab1e', linewidth=2, label='Recta de regresión')

plt.xlabel('Horas de estudio')
plt.ylabel('Calificación')
plt.title('Regresión Lineal Simple')
plt.legend()
plt.tight_layout()
plt.show()
```

Siempre grafica los datos y la recta ajustada — visualizar el ajuste es tan importante como calcular R^2 .

Predicciones e interpretación

Haciendo predicciones

Una vez entrenado el modelo, predecir es directo:

```
# ¿Qué calificación obtendrá un alumno que estudia 9 horas?  
horas_nuevas = np.array([[9]])  
prediccion = modelo.predict(horas_nuevas)  
print(f"Calificación estimada: {prediccion[0]:.1f}")
```

Cuidados al predecir:

- No extrapolar más allá del rango de entrenamiento
- Una predicción puntual siempre tiene un **intervalo de confianza**
- El modelo asume que la relación lineal se mantiene

Interpretación de coeficientes

Supón que el modelo arroja: $\hat{y} = 38.5 + 6.2x$

 $\beta_0 = 38.5$ — Un alumno que estudia 0 horas obtendría ~38.5 puntos (base de referencia)

 $\beta_1 = 6.2$ — Por cada hora adicional de estudio, la calificación sube ~6.2 puntos

La **pendiente** es el coeficiente más informativo: cuantifica el efecto de X sobre Y.

Conexión con la semana anterior

Semana 5	Semana 6
Correlación de Pearson (r)	Regresión lineal (β_1)
Mide la fuerza de la relación	Cuantifica y predice la relación
Resultado: valor entre -1 y 1	Resultado: ecuación de la recta
No tiene dirección causal	Establece X como predictor de Y

Un r alto entre X e Y es condición favorable (no suficiente) para una buena regresión.

Para esta semana

- [] Comprender la ecuación $\hat{y} = \beta_0 + \beta_1 x$ y el significado de cada término
- [] Calcular los coeficientes usando mínimos cuadrados
- [] Implementar `LinearRegression` de scikit-learn y evaluar con R^2 y RMSE
- [] Graficar los datos y la recta ajustada con `matplotlib`
- [] **Actividad:** ajustar un modelo a un dataset real (ej. precios, temperaturas, ventas)

Próxima sesión

Reducción de dimensionalidad · métodos multivariados · selección de variables