

Ciencia de Datos

Análisis de Componentes Principales (PCA): reducción de dimensionalidad y selección de variables

¿Qué es el Análisis de Componentes Principales?

PCA es una técnica de **reducción de dimensionalidad** que transforma variables correlacionadas en un conjunto menor de variables no correlacionadas llamadas **componentes principales**.

- Conserva la mayor cantidad posible de **información (varianza)**
- Facilita la **visualización** de datos con muchas variables
- Es la base de varios métodos multivariados de análisis

¿Por qué reducir la dimensionalidad?

- Los conjuntos de datos reales pueden tener **decenas o cientos de variables**
- Problemas comunes al trabajar con muchas dimensiones:
 - "Maldición de la dimensionalidad"
 - Variables redundantes o altamente correlacionadas
 - Dificultad para **visualizar** más de 3 dimensiones
 - Modelos más lentos y propensos a sobreajuste

Fundamentos matemáticos de PCA

Repaso: varianza y covarianza

- **Varianza:** qué tanto se dispersan los valores de una variable respecto a su media
- **Covarianza:** cómo varían **conjuntamente** dos variables
- La **matriz de covarianza** resume estas relaciones para todas las variables del conjunto de datos

 PCA parte de la matriz de covarianza (o de correlación) para encontrar las direcciones de máxima variabilidad.

Componentes principales

- Cada **componente principal** es una combinación lineal de las variables originales
- Se obtienen a partir de los **eigenvectores** (direcciones) y **eigenvalores** (magnitud de varianza) de la matriz de covarianza
- **PC1**: dirección con la mayor varianza posible
- **PC2**: dirección ortogonal a PC1 con la segunda mayor varianza
- Y así sucesivamente...

Pasos del algoritmo PCA

1. **Estandarizar** los datos (media 0, desviación estándar 1)
2. Calcular la **matriz de covarianza**
3. Obtener **eigenvectores y eigenvalores**
4. Ordenar los componentes según la **varianza explicada**
5. **Proyectar** los datos sobre los componentes seleccionados

PCA en Python con scikit-learn

Paso 1 — Estandarización de los datos

```
from sklearn.preprocessing import StandardScaler
import pandas as pd

df = pd.read_csv("datos.csv")

scaler = StandardScaler()
X_scaled = scaler.fit_transform(df)
```

⚠ PCA es sensible a la escala de las variables: si una variable está en miles y otra en decimales, dominará el análisis si no se estandariza.

Paso 2 — Aplicar PCA

```
from sklearn.decomposition import PCA

pca = PCA(n_components=2)
componentes = pca.fit_transform(X_scaled)

# Varianza explicada por cada componente
print(pca.explained_variance_ratio_)
```

- `n_components` define cuántos componentes conservar
- `explained_variance_ratio_` indica el porcentaje de información retenida

Paso 3 — Varianza explicada acumulada

```
import matplotlib.pyplot as plt

pca_full = PCA().fit(X_scaled)
varianza_acumulada = pca_full.explained_variance_ratio_.cumsum()

plt.plot(range(1, len(varianza_acumulada) + 1),
         varianza_acumulada, marker='o')
plt.xlabel("Número de componentes")
plt.ylabel("Varianza explicada acumulada")
plt.title("Scree plot")
plt.show()
```

Paso 4 — Visualizar los componentes

```
import seaborn as sns

sns.scatterplot(x=componentes[:, 0], y=componentes[:, 1])
plt.xlabel("Componente Principal 1")
plt.ylabel("Componente Principal 2")
plt.title("Proyección de los datos en PC1 y PC2")
plt.show()
```

💡 Si los datos forman grupos visibles en el gráfico, PCA puede revelar patrones que no eran evidentes en las variables originales.

Selección de variables y análisis de dispersión

PCA vs. Selección de variables

Selección de variables	PCA
Conserva las variables originales	Crea nuevas variables (combinaciones lineales)
Resultados fáciles de interpretar	Componentes difíciles de interpretar
Elimina columnas poco relevantes	Reduce dimensionalidad preservando varianza
Métodos: filtro, <i>wrapper</i> , embebidos	Método: transformación lineal del espacio

¿Cuándo usar PCA?

- ✓ **Alta correlación** entre variables — PCA elimina la redundancia
- ✓ **Visualización** de datos con muchas dimensiones en 2D o 3D
- ✓ **Acelerar modelos** reduciendo el número de variables de entrada
- ⚠ **Limitación:** se pierde la interpretabilidad de las variables originales

Casos reales de PCA

- **Imágenes:** compresión y reconocimiento facial (reducción de miles de píxeles a pocos componentes)
- **Genómica:** análisis de miles de genes resumidos en componentes principales
- **Finanzas:** combinación de múltiples indicadores económicos correlacionados
- **Sistemas de recomendación:** reducción de matrices usuario-producto

Evaluación de Unidad II

Proyecto práctico — Evaluación Unidad II

Informe de análisis exploratorio con métricas estadísticas

El informe debe integrar lo trabajado en las semanas 5 a 7:

- **Semana 5:** medidas de tendencia central y dispersión del conjunto de datos elegido
- **Semana 6:** un modelo de regresión lineal con su ecuación e interpretación
- **Semana 7:** un análisis de PCA, incluyendo varianza explicada y visualización de componentes



Entregable: documento técnico + notebook de Python (Jupyter/Colab) con el código y las visualizaciones.

Para esta semana

- [] Entender qué es la reducción de dimensionalidad y por qué es útil
- [] Aplicar PCA con `scikit-learn` sobre un conjunto de datos propio
- [] Interpretar la varianza explicada y el *scree plot*
- [] Avanzar en el **Proyecto práctico de Evaluación de Unidad II**

Próxima sesión

Fundamentos de aprendizaje automático: conceptos básicos de Machine Learning, tipos de aprendizaje, ciclo de vida de un modelo y librerías como scikit-learn