

Redes Neuronales para Audio

Arquitecturas recurrentes, convolucionales y generativas aplicadas al procesamiento de audio

¿Por qué el audio es un reto distinto?

- Es una señal **secuencial y temporal** (no una "foto" estática)
- Alta tasa de muestreo: miles de valores por segundo
- Se puede representar de dos formas principales:
 - **Forma de onda (waveform)** — señal cruda en el tiempo
 - **Espectrograma** — representación tiempo-frecuencia (imagen)

💡 Esta doble naturaleza (secuencia *o* imagen) explica por qué se usan tanto redes recurrentes como convolucionales para audio.

Redes Recurrentes para Audio

RNN, LSTM y GRU

- **RNN (Red Neuronal Recurrente)**: procesa la señal paso a paso, manteniendo una "memoria" del pasado
- **LSTM (Long Short-Term Memory)**: resuelve el problema de memoria corta de las RNN mediante compuertas (gates)
- **GRU (Gated Recurrent Unit)**: versión simplificada de LSTM, más rápida de entrenar

Usos típicos en audio:

Reconocimiento de voz · generación de música nota a nota · traducción de voz a texto (speech-to-text)

Ventajas y limitaciones

Recurrentes (RNN/LSTM/GRU)	Limitación principal
Capturan dependencias temporales	Entrenamiento lento (secuencial)
Buenas con secuencias largas (LSTM)	Difícil de paralelizar en GPU
Naturales para series de tiempo	Pueden "olvidar" contexto muy lejano

Redes Convolucionales para Audio

CNN aplicadas a audio

- El audio se convierte en **espectrograma** (imagen tiempo-frecuencia)
- Una vez en forma de imagen, se procesa igual que una foto: con **convoluciones**
- Detectan patrones locales: timbres, formantes, ataques de notas, fonemas

 Ejemplo: clasificación de géneros musicales o detección de palabras clave ("Hey Siri", "OK Google") usando CNN sobre espectrogramas.

Redes Generativas para Audio

Modelos generativos de audio

- **WaveNet**: red convolucional causal que genera audio muestra por muestra (voz muy natural)
- **GAN de audio (WaveGAN, GANSynth)**: un generador crea audio y un discriminador lo evalúa contra audio real
- **Modelos de difusión de audio**: parten de ruido y lo van "limpiando" hasta obtener una señal coherente
- **Transformers de audio** (ej. Whisper, MusicGen): usan atención en vez de recurrencia, muy usados hoy en día

Usos: síntesis de voz (text-to-speech), composición musical, clonación de voz,

Comparación general de arquitecturas para audio

Tipo	Fortaleza	Ejemplo de uso
Recurrente (RNN/LSTM)	Secuencias, dependencia temporal	Speech-to-text
Convolutacional (CNN)	Patrones locales sobre espectrograma	Clasificación de sonidos
Generativa (WaveNet, GAN, Difusión)	Crear audio nuevo y realista	Text-to-speech, música
Transformer	Contexto largo, paralelizable	Whisper, MusicGen

Redes Neuronales Convolucionales (CNN)

Arquitectura a fondo

¿Qué es una CNN?

Una arquitectura de red neuronal diseñada para procesar datos con estructura de **cuadrícula** (imágenes, espectrogramas, video).

- En lugar de conectar todas las neuronas entre sí, usa **filtros (kernels)** que se deslizan sobre la entrada
- Aprende automáticamente qué características son importantes (bordes, texturas, formas)
- Reduce drásticamente el número de parámetros frente a una red totalmente conectada

Tipos de capas en una CNN

- **Capa convolucional** — aplica filtros para extraer características (bordes, patrones)
- **Capa de activación (ReLU)** — introduce no linealidad
- **Capa de pooling (max/average)** — reduce dimensionalidad, conserva lo importante
- **Capa de normalización (Batch Normalization)** — estabiliza y acelera el entrenamiento
- **Capa de dropout** — apaga neuronas al azar para evitar sobreajuste
- **Capa totalmente conectada (Fully Connected / Dense)** — combina características para la predicción final

Capa convolucional en detalle

- **Filtro / kernel**: matriz pequeña (ej. 3×3) que se desliza sobre la entrada
- **Stride**: cuánto se mueve el filtro en cada paso
- **Padding**: relleno en los bordes para controlar el tamaño de salida
- **Mapa de características (feature map)**: resultado de aplicar el filtro

🔍 Cada filtro aprende a detectar un patrón distinto: en capas tempranas, bordes y colores; en capas profundas, formas complejas.

Capa de pooling

- **Max pooling:** conserva el valor máximo de una región
- **Average pooling:** conserva el promedio de una región
- Objetivo: reducir el tamaño espacial y hacer la red más robusta a pequeñas variaciones (traslación, ruido)

¿Cómo se define la arquitectura de una CNN?

1. **Entrada** — tamaño de la imagen o espectrograma (ancho × alto × canales)
2. **Bloques convolucionales** — se apilan capas conv + activación + pooling, aumentando el número de filtros en cada bloque
3. **Aplanado (Flatten)** — se convierte el mapa de características en un vector
4. **Capas densas** — combinan la información para la tarea final
5. **Capa de salida** — softmax (clasificación) o lineal (regresión)

Regla general: entre más profunda la red, más filtros por capa, pero menor tamaño espacial.

Ejemplo de arquitectura simple (Keras)

```
from tensorflow.keras import layers, models

modelo = models.Sequential([
    layers.Conv2D(32, (3,3), activation='relu', input_shape=(128,128,1)),
    layers.MaxPooling2D((2,2)),
    layers.Conv2D(64, (3,3), activation='relu'),
    layers.MaxPooling2D((2,2)),
    layers.Flatten(),
    layers.Dense(64, activation='relu'),
    layers.Dropout(0.5),
    layers.Dense(10, activation='softmax')
])
```

¿Para qué más sirven las CNN?

- **Clasificación de imágenes** — identificar objetos, animales, enfermedades en radiografías
- **Detección de objetos** — ubicar y etiquetar múltiples objetos en una imagen
- **Segmentación** — clasificar cada píxel (ej. imágenes médicas, autos autónomos)
- **Video** — análisis frame a frame o con convoluciones 3D
- **Audio (espectrogramas)** — como vimos, clasificación de sonidos y voz
- **Series de tiempo** — convoluciones 1D sobre señales secuenciales

Para esta sesión

- [] Distinguir cuándo usar redes recurrentes, convolucionales o generativas en audio
- [] Explicar el rol de cada tipo de capa en una CNN
- [] Describir cómo se construye una arquitectura CNN de principio a fin
- [] Identificar aplicaciones de CNN más allá del audio

Gracias

Cualquier duda, retomamos en la próxima sesión